

# Geri Alma-Artırılmış Üretim(RAG) Sistemlerinde Vektör Veritabanı ve LLM Modellerinin Değerlendirilmesi

## Evaluation of Vector Database and LLM Models in Retrieval-Augmented Generation (RAG) Systems

Hilal Tekgöz  
Ar-Ge Birimi  
Loodos Teknoloji A.Ş.  
İstanbul, Türkiye  
hilal.tekgoz@loodos.com

Halit Erdoğan  
Ar-Ge Birimi  
Loodos Teknoloji A.Ş.  
İstanbul, Türkiye  
halit.erdogan@loodos.com

Harun Uz  
Ar-Ge Birimi  
Loodos Teknoloji A.Ş.  
İstanbul, Türkiye  
harun.uz@loodos.com

Hatice Altınok  
Ar-Ge Birimi  
Loodos Teknoloji A.Ş.  
İstanbul, Türkiye  
hatice.altinok@loodos.com

**Öz**—Büyük Dil Modelleri (LLM'ler) birçok farklı alanda oldukça başarılı sonuçlar vermiştir. Ancak, güncelliğini yitirmiş ve yanlış bilgiler yerine gerçeklikten uzak bilgiler içeren sonuçlar üretebilirler. Bu sorunlara bir çözüm olarak, Geri Alma Artırılmış Üretimi (RAG) yaklaşımı öne çıkmaktadır. RAG, üretim sürecine harici bilgi kaynaklarını entegre ederek, özellikle bilgi yoğun görevlerde doğruluk ve zamanındalık açısından önemli avantajlar sunmaktadır. Bu çalışma, Türkçe için tasarlanmış birden fazla RAG mimarisinin sistematik ve karşılaştırmalı bir değerlendirmesini sunmaktadır. RAG boru hattındaki çeşitli bileşenlerin (FAISS, QDRANT, Chroma) ve benzerlik ölçütlerinin (kosinüs, Öklid vb.) geri alma performanslarını karşılaştıran bir çalışmayı içermektedir. Bulgularımız, düşük kaynaklı dil ortamlarında RAG sistemlerinin verimliliğini ve güvenilirliğini etkileyen kritik tasarım seçimlerini vurgulamaktadır.

**Anahtar Sözcükler**—doğal dil işleme, geri alma-artırılmış üretim, vektör veritabanı, benzerlik, üretim

**Abstract**—Large Language Models (LLMs) have achieved notable success in various fields. However, they can generate results that, while not necessarily outdated or factually incorrect, may be somewhat unrealistic. To address these issues, the Retrieval Augmented Generation (RAG) approach has emerged as a promising solution. RAG significantly enhances accuracy and timeliness, especially in information-intensive tasks, by incorporating external information sources into the content generation process. This study provides a systematic and comparative evaluation of multiple RAG architectures specifically designed for the Turkish language. It includes an analysis of the retrieval performances of different components (such as FAISS, QDRANT, and Chroma) and similarity measures (including cosine and Euclidean distances) within the RAG pipeline. Our findings underscore critical design choices that influence the efficiency and reliability of RAG systems in low-resource language settings.

**Keywords**—natural language processing, retrieval-augmented generation, vector database similarity, generation

### I. GİRİŞ

Günümüzde büyük dil modelleri (LLM'ler), teknolojinin gelişmesiyle birlikte oldukça başarılı sonuçlar vermektedir. LLM modelleri, cevap üretme, metin özetleme, duygu analizi ve anahtar kelime çıkarımı gibi görevlerde oldukça başarılı sonuçlar vermektedir. Bununla birlikte, bu başarılarla rağmen, dil modellerinin çoğu zaman etkisine dayalı, yüksek miktarda ve dış kaynaklara sahip iyileştirilmiş yanıtlar üretememesi önemli bir zorluk olarak mevcut değildir. Ancak, Geri Alma-Artırılmış Üretimi (Retrieval-Augmented Generation, RAG) mimarisi, modelin yalnızca kendi kendine eğitildiği veriye dayanmak yerine, harici bilgi kaynaklarına saklanması sağlayarak daha sağlam, açıklayıcı ve güvenilir yanıtlar üretmesine destek olmaktadır [1]. Böylece sistem, önce dış kaynaklardan ilgili bilgiyi bulmakta ve ardından bu bilgiye dayanarak kullanıcıya yanıt üretmektedir.

RAG tabanlı sistemler, elde edilen literatür taramasında İngilizce gibi evrensel diller üzerindedir. Fakat, Türkçe gibi dil yapısı bakımından zengin ve kaynak çeşitliliği sınırlı olan dillerde RAG sistemlerinin nasıl performans gösterdiğine dair kapsamlı çalışmalar oldukça azdır. Bu da Türkçe dilinde çalışan RAG tabanlı yapay zeka sistemlerinin güvenilirliğini doğrudan etkileyen bir çalışma alanı olarak değerlendirilmektedir.

Bu çalışma, Türkçe için tasarlanmış çeşitli RAG yapılarını karşılaştırmalı olarak incelemeyi amaçlamaktadır. Geliştirilen

deneysel yöntemler, çeşitli bilgi erişim mekanizmaları ve metin üretim modelleri ile test edilmiştir. Bu süreçte, yanıtların doğruluğu, içeriğe uygunluğu ve üretim süresi gibi çeşitli ölçütler üzerinden değerlendirmeler yapılmıştır.

Bilgiye dayalı yanıtlama sistemlerinin daha güvenilir, şeffaf ve erişilebilir hale gelmesi, yalnızca akademik araştırma için değil, aynı zamanda eğitim, kamu hizmetleri ve müşteri destek sistemleri gibi birçok alanda da kullanılabilmektedir. Bu çalışmanın temel amacı da, bu potansiyele katkı sunacak yapısal karşılaştırmalar ortaya koymak ve Türkçe’de RAG mimarisinin güçlü ve zayıf yönlerini ortaya çıkarmaktır.

## II. İLGİLİ ÇALIŞMALAR

Büyük Dil Modelleri (LLM’ler), doğal dil işleme (NLP) alanında önemli bir ilerleme kaydederek çok sayıda kullanım alanında önemli bir başarı elde etmiştir. Generative Pre-trained Transformers (GPT) [2], LLaMA [3] ve Gemini [4] gibi örnekler, bağlama uygun ve anlamsal olarak oluşturma yeteneğine sahiptir. Aynı zamanda, bu modellerin hatalı veya doğru olmayan içerikler üretme eğiliminde olması önemli bir geliştirme konusu olarak değerlendirilmektedir [5]. Literatürde halüsinasyon olarak adlandırılan bu durum günümüzde hala üzerinde yoğun biçimde çalışılan bir araştırma konusudur [6]. Halüsinasyon, doğru ve anlamsal olarak alakalı çıktılar üretebilmek adına Geri Alma-Artırılmış Üretimi (Retrieval-Augmented Generation, RAG) gibi yöntemler öne çıkmaktadır.

Bilgi getirme ile üretici modelleri birleştirerek doğal dil işleme performansını artırmayı hedefleyen RAG [7] yaklaşımı, son dönemde dikkat çeken bir yöntemdir [8]. Dış bilgi veri tabanlarından yararlanarak, RAG sistemleri daha doğru ve anlamsal olarak alakalı çıktılar üretebilmektedir [8]. RAG’ın geri alma ve metin üretimini birleşik bir çerçevede dinamik olarak sunması NLP sistemlerinin performansını iyileştirme potansiyelini artırmıştır. RAG sistemi, bilim, finans, eğitim, sağlık, hukuk ve endüstri gibi birçok alanda bilgi getirme ve üretme yeteneklerini birleştirerek performansı önemli ölçüde artırmaktadır. Bu modeller, karmaşık veri kümelerinden bağlama uygun, güncel ve doğru bilgileri alarak daha verimli karar destek sistemleri sunmaktadır. RAG modelleri bilimsel araştırma alanında geniş veri tabanlarından güncel bilgileri çekerek araştırmacılara önemli destek sunmaktadır [8]. Örneğin, RAG tabanlı ChemLit-QA [9] kimyada sentez planlama ve reaksiyon tahmini gibi görevlerde disipline özgü sorguları geliştirmektedir. Aynı şekilde Biorag [10] sistemi, biyoloji ve yaşam bilimlerinde araştırmacılara hızlı ve etkili bilgi sağlamak için geliştirilmiştir. Geleneksel Çin tıbbında eski kaynaklarda ki bilgilere erişimi kolaylaştırmak için RAG tabanlı bir sistem geliştirilmiştir. Çalışmada veriler düğümler ve ilişkiler şeklinde bir grafik veri tabanında tutulup RAG tekniği kullanılarak, soru-cevap süreçlerinde bağlam zenginleştirilmiştir [11]. Hukuk alanında, CBR-RAG [12] ile bağlamsal olarak ilgili davaların geri getirilmesi sağlanmaktadır. Yapılan bir başka çalışmada, hukuk ve politika alanındaki yapay zeka uygulamalarında doğruluğu artırmak için sorgu

karmaşıklığını dikkate alarak hibrit geri alma stratejileri kullanan ve NYC Yerel Yasası 144 üzerinde test edilen RAG tabanlı HyPA-RAG [13] adlı bir sistem geliştirilmiştir. Endüstride, endüstriyel ortamlarda gerçek zamanlı sorun çözme amacıyla, bilgi çekme (retrieval) ve üretme (generation) yeteneklerini birleştiren RAG modelleri geliştirilmiş ve kullanılmıştır. Yapılan çalışmalar, RAG tabanlı sistemlerin operasyonel verimliliği artırarak arıza çözüm süresini azaltmada etkili olmuştur. [14].

## III. UYGULAMA METOTLARI

### A. Büyük Dil Modelleri (LLM’ler)


Büyük Dil Modelleri (LLM’ler) [15], özellikle 2020’den bu yana, kapsamlı ve büyük veri kümeleri üzerinde eğitilerek dil anlama ve üretme görevlerinde dikkate değer başarılı sonuçlar elde etmiştir. Bu modeller, hem genel dil üretimi ve soru cevaplama hem de metin tamamlama ve özetleme gibi bilgiye ihtiyaç olan görevlerde insan düzeyinde veya insanı aşan başarılar göstermektedir. LLM’lerin temel özelliklerinden biri bağlamsal dili anlama ve karmaşık bilgileri bütünleştirme kapasiteleridir. Transformer tabanlı çok katmanlı dikkat mekanizmaları sayesinde, veri içindeki ilişkileri kavrayıp farklı bilgileri tutarlı ve akıcı biçimde birleştirebilirler. LLM modelleri geniş çaplı veriler üzerinde eğitildikleri için, bazen güncel olmayan, hatalı veya bağlama uygun olmayan içerikler üretebilmektedir [16]. Bu olguya literatürde “halüsinasyon” adı verilmektedir [16]. Özellikle yüksek bilgi yoğunluğu ve doğruluğunun önemli olduğu endüstriyel ve teknik bağlamlarda sistem, yanlış ve bağlamsal olarak uygunsuz içerik üretebilmektedir. Bu nedenle, modelin güvenilirliğini etkileyen önemli bileşenlerden biri olarak gösterilmektedir [17].

Çalışmamızda metin üretme bileşeni olarak OpenAI’nin GPT-4o modeli ve Google’ın Gemini modeli kullanılmıştır. GPT, çok büyük parametre sayısına sahip, ileri düzey bir transformer tabanlı dil modeli olup, doğal dil işleme görevlerinde yüksek doğruluk oranı vermektedir [8]. Google tarafından geliştirilen Gemini modeli ise, güncel mimari geliştirmelerle optimize edilmiş, çok modlu ve çok görevli öğrenme özelliklerine sahip bir büyük dil modeli olarak öne çıkar. Gemini, özellikle dil anlama ve üretme süreçlerinde daha hızlı ve hassas sonuçlar sunabilmek amacıyla tasarlanmıştır.

### B. Geri Alma-Artırılmış Üretimi (RAG)

Büyük dil modelleri (LLM) olağanüstü yetenekleri sayesinde doğal dil işleme (NLP) sektörünün önemli bir parçası haline gelmiştir [18]. LLM’ler büyük miktarda veriyle eğitilmiş olmalarına rağmen hala halüsinasyon gibi gerçek dışı yanıtlar üretebilmektedirler. Bu aşamada devreye Geri Alma-Artırılmış Üretim (RAG) sistemleri girmiştir. LLM’lerin halüsinasyon görmesini önlemek amacıyla, LLM’lerin harici bilgi kaynaklarından (yani vektör veritabanlarından) anlamlı içerikler alması, doğruluk ve güvenilirlik açısından umut verici bir yaklaşımdır [19]. RAG yaklaşımı iki aşamadan oluşur. Bunlar şekil 1’de de görüldüğü üzere alma (retrieval)

ve üretme (generation) aşamalarıdır.



Şekil 1. RAG mimarisi.

Bu iki aşamalı yapının ilk adımı olan alma (retrieval) sürecinde, kullanıcıdan gelen sorguya uygun içeriklerin dış bilgi kaynaklarından alınması hedeflenmektedir. Bunun için klasik kelime temelli alma yöntemlerinden biri olan BM25 algoritması ile semantik düzeyde benzerlik kurabilen dense retriever yaklaşımları bir arada kullanılabilir. BM25, kelime frekansına dayalı olarak belge ile sorgu arasındaki benzerliği ölçerken [20], dense retriever ise derin öğrenme tabanlı gömmeler (embedding) üzerinden çalışarak daha anlam temelli eşleşmeler sağlamaktadır [21]. Her iki yöntemin avantajlarını birleştirmek amacıyla, bu çalışmada EnsembleRetriever yapısı kullanılmıştır. EnsembleRetriever, hem seyrek(sparse) hem de yoğun(dense) yaklaşımları aynı anda değerlendirerek daha doğru bilgi alımını sağlamaktadır. İkinci aşama olan üretme (generation) kısmında ise, alma aşamasında getirilen belgeler bağlamında dil modeli tarafından nihai yanıt oluşturulur. Bu bağlamlama süreci, LLM'lerin yalnızca eğitim verisine dayalı üretim yapması yerine, güncel ve doğrulanabilir bilgilere erişerek yanıt oluşturmalarını mümkün kılar. Böylece modelin halüsinasyon üretme olasılığı azaltılırken, aynı zamanda yanıtların bilgiye dayalı ve bağlamsal olarak tutarlı olması sağlanır [22].

#### IV. DENEYSEL ÇALIŞMALAR

##### A. Sistem Tasarımı

Bu çalışmada, bilgiye dayalı görevlerde RAG sistemlerinin performansını analiz etmek amacıyla deneysel çalışmalar yapılmıştır. RAG mimarisi, LLM'lere göre daha güncel, doğrulanabilir ve bağlamsal olarak zengin içerikler üretmeyi amaçlamaktadır. Deneysel çalışmada kullanılan veri seti, Loodos firmasında İnsan Kaynakları (İK) süreçlerinde çalışanları bilgilendirmek amacıyla kullanılan kurumsal dokümanlardan oluşmaktadır. Bu dokümanlar, şirket içi bilgi paylaşımını sağlamak ve çalışanların sorularına yanıt vermek üzere yapılandırılmıştır. Dokümanlar çeşitli formatlarda (PDF, CSV, Excel, HTML, metin dosyaları) toplanmış ve ön işleme tabi tutulmuştur. Kullanılan veri seti, Türkçe dilinde hazırlanmış ve sadece kuruma özgü içerik barındırması bakımından özgün bir nitelik taşımaktadır. Bu kapsamda, toplamda 12 farklı RAG akışları (pipeline) yapılandırılmış ve karşılaştırmalı olarak test edilmiştir. Çalışmada şekil 2'deki akış üzerinden ilerlenilmiştir. Her pipeline, iki ana


bileşenden oluşmaktadır: belge erişimi(retrieval) ve metin üretimi(generation) katmanları.

Retrieval bileşeninde FAISS, Qdrant ve Chroma olmak üzere üç farklı vektör veritabanı kullanılmıştır. Bu vektör tabanlı arama sistemleri, sorguya en yakın belgeleri bulmak için belge gömmelerini kullanmaktadır. Her vektör veri tabanı, kosinüs ve öklid olmak üzere iki farklı benzerlik ölçütü ile ayrı ayrı test edilmiştir. Böylece her veritabanı için iki ayrı yapılandırma (örneğin: "Qdrant + Öklid" ve "Qdrant + Kosinüs") oluşturulmuştur.

Generation bileşeninde ise OpenAI GPT-4o ve Google Gemini Pro olmak üzere iki LLM kullanılmıştır. Her bir retrieval bileşeni bu iki LLM ile birleştirilerek, toplamda 3 (vektör DB) × 2 (benzerlik) × 2 (LLM) = 12 farklı pipeline tanımlanmıştır.

##### B. Embedding Yöntemleri

Retrieval performansını etkileyen temel bileşenlerden biri de gömme yöntemidir. Belgeler ve sorgular, uygun vektör temsillere dönüştürülmeden vektör veri tabanı içinde benzerlik karşılaştırması yapılamaz. Bu çalışmada, kullanılan her pipeline'ın gömme oluşturma süreci de model seçimine göre belirlenmiştir.



Şekil 2. Çalışmanın sistem tasarım aşamaları.

Dokümanlar önce normalize edilip, parçalara (chunk) bölünmüştür. Chunk büyüklüğü ve çıkış parametreleri deneysel olarak belirlenmiştir. Ardından, metinler gömme işlemi için uygun formata getirilmiş ve gömme modelleri olarak OpenAI'nın text-embedding-3-large ve Google'ın text-embedding-004 modelleri kullanılmıştır. text-embedding-3-large modeli, metinleri en fazla 8191 token sayısına göre, boyutu N = 3072 olan vektörler oluşturmaktadır [23]. Google Gemini'nin text-embedding-004 modeli 768 boyutlu bir vektör çıktısı vermektedir.

Her pipeline için seçilen vektör depolama ve mesafe metriğiyle gömme sonuçları üzerinden indeksleme yapılmıştır. Ardından retrieval sorguları bu indeksler üzerinde çalıştırılmıştır. Retrieval sonuçları, ilgili üretim

modeline girdi olarak verilmiştir.

### C. Değerlendirme

Deneyisel çalışmalar, Türkçe dilinde bilgiye dayalı soru-cevap görevleri üzerinde gerçekleştirilmiştir. Test veri seti, Loodos İK veri seti içerisinde bulunan genel bilgilerden teknik bilgilere kadar çeşitli içerikleri kapsamaktadır. Çalışma kapsamında oluşturulan her bir RAG pipeline, Loodos firmasının İnsan Kaynakları süreçlerine ilişkin kurumsal dokümanlar üzerinde yapılandırılmış sabit bir soru seti ile test edilmiştir. Değerlendirme sürecinde, sistemlerin yanıt üretme başarısını iki temel ölçüt üzerinden analiz edilmiştir: yanıtların doğruluğu ve üretim aşamalarının toplam yanıt süresi. Bu değerlendirme metrikleri sayesinde, sadece yanıt kalitesi değil aynı zamanda sistemlerin zaman verimliliği de göz önünde bulundurulmuştur. Üretim (generation) aşamasında yapılan çalışmalarda, OpenAI GPT-4o modelinin yanıt üretme süresinin, Google Gemini modeline göre daha uzun olduğu sonucuna ulaşılmıştır.

Deneyisel sonuçların, tablo I incelendiğinde, pipeline bileşenlerinin (retrieval veritabanı, benzerlik metriği ve LLM) sistem performansı üzerinde anlamlı bir etkiye sahip olduğunu göstermiştir. En yüksek performans, Chroma vektör veritabanı ile kosinüs benzerliği kullanılarak ve Gemini modeliyle yapılan üretim süreci sonucunda elde edilmiştir. Chroma ve kosinüs benzerliğinin yüksek başarımlı göstermesi chroma veritabanının hızlı indeksleme ve bellek yapısı yetenekleri ile kosinüs metriklerinin semantik yakınlığı daha başarılı yakalamasından kaynaklandığı gözlemlenmiştir. Diğer yandan, Qdrant veritabanı ve GPT-4o modeli ile oluşturulan bazı pipeline'lar da 0.90 doğruluk düzeyiyle oldukça yüksek başarı göstermiştir. Buna karşılık, FAISS veri tabanının bazı varyasyonlarında, özellikle cosine metrikli GPT-4o kombinasyonlarında, doğruluk skorlarının 0.81'e kadar düştüğü gözlemlenmiştir. FAISS ve GPT-4o akışında düşük performans gözlemlenmesi, text-embedding-3-large gömme modelinin vektör temsillerinin benzerlik skoru üretmede yetersiz kalması ile ilişkilidir.

TABLO I. RAG SİSTEMLERİNİN DOĞRULUK PERFORMANSI

| Retriever DB | Gömme                  | Benzerlik Ölçütü | Üretim         | Başarı (%) |
|--------------|------------------------|------------------|----------------|------------|
| Chroma       | text-embedding-004     | Kosinüs          | gemini-1.5-pro | 96.00      |
| Qdrant       | text-embedding-004     | Öklid            | gemini-1.5-pro | 93.00      |
| Qdrant       | text-embedding-004     | Kosinüs          | gemini-1.5-pro | 90.00      |
| Qdrant       | text-embedding-3-large | Kosinüs          | GPT-4o         | 90.00      |
| FAISS        | text-embedding-004     | Öklid            | gemini-1.5-pro | 90.00      |
| FAISS        | text-embedding-3-large | Kosinüs          | GPT-4o         | 81.00      |
| FAISS        | text-embedding-004     | Kosinüs          | gemini-1.5-pro | 86.00      |
| Chroma       | text-embedding-004     | Öklid            | gemini-1.5-pro | 83.00      |
| Chroma       | text-embedding-3-large | Kosinüs          | GPT-4o         | 91.00      |
| FAISS        | text-embedding-3-large | Öklid            | GPT-4o         | 86.00      |
| Chroma       | text-embedding-3-large | Öklid            | GPT-4o         | 90.00      |
| Qdrant       | text-embedding-3-large | Öklid            | GPT-4o         | 86.00      |

Sonuçlar, gömme modelinin retrieval performansına doğrudan etki ettiğini göstermektedir. Özellikle Google gömme modelinin kullanıldığı Gemini tabanlı sistemler, genel olarak GPT-4o tabanlı pipeline'lara kıyasla daha yüksek doğruluk sağlamıştır. Aynı retrieval mimarisiyle yapılan karşılaştırmalarda bile gömme modelinin farkı ortaya çıkmaktadır. Örneğin Chroma + Kosinüs yapılandırmasında Gemini modeli (Google gömme) %96 doğruluk elde ederken, GPT-4o (OpenAI gömme) %91'de kalmıştır. Bu da gösteriyor ki RAG sistemlerinin başarısında yalnızca dil modeli ya da

retriever değil, gömme katmanının kalitesi ve modelle uyumu da belirleyici bir faktördür. Ayrıca elde edilen sonuçlar, sadece doğruluk oranı ile değil, aynı zamanda kurulan sistemin cevap üretme süresi ve gömme yöntemi ile LLM uyumu açısından da değerlendirilmiştir. Bu da Türkçe RAG sistemlerinin daha verimli hale getirilmesi için önemli sistem akışı önerileri sunmaktadır.

Sistem performansının canlı ortamda nasıl çalıştığını analiz edebilmek adına, çalışanların sıkça karşılaştığı günlük bilgi talepleriyle sistemin yanıt üretme performansı test edilmiştir. Örneğin, bir kullanıcı "Arife günü tatil mi?" diye bir soru sorduğunda geliştirilen sistem "Ramazan, Kurban ve Cumhuriyet Bayramı tatilleri arife günleri saat 13.00 itibarıyla başlar. Yani arife günleri yarım gün resmi tatildir." şeklinde bir cevap üretmektedir. Ayrıca kullanıcının detaylı bilgiye erişimini kolaylaştırmak için şirket içindeki iç kaynaklara yönlendiren bir bağlantı linki de göndermektedir.

### V. SONUÇLAR VE GELECEK ÇALIŞMALAR

Bu çalışma, Geri Alma-Artırılmış Üretim (RAG) mimarisi kullanılarak oluşturulan çeşitli RAG (boru hattı) bileşenleri arasındaki etkileşimleri ve bunların sistem performansını nasıl etkilediğini kapsamlı bir şekilde incelemiştir. Deneyisel bulgulara göre, geri alma ve üretim süreçleri ayrı ayrı değil, birbirleriyle ilişkili olarak değerlendirilmelidir. Çalışmada en yüksek performans, Chroma vektör veritabanı ile kosinüs benzerliği kullanılarak ve Gemini modeliyle yapılan üretim süreci sonucunda elde edilmiştir. Özellikle Chroma ve Qdrant olmak üzere güncel vektör veritabanlarının kullanılması, bilgi alma kalitesini artırmakta ve genel olarak sistem performansını olumlu yönde etkilemektedir. Benzer şekilde, kosinüs benzerliği gibi semantik yakınlık ölçümünde daha etkili olan metriklerin tercih edilmesi, yüksek doğruluk oranlarına ulaşılmasında belirleyici rol oynamaktadır.

Gelecekteki çalışmalarda, çok modlu veri kaynaklarının ve farklı dildeki dokümanların dahil edilmesi, geliştirilen sistemin dinamikleştirilebilirliği test etme açısından önemli bir araştırma alanı olarak değerlendirilebilir. Bu doğrultuda, RAG mimarilerinin kurumsal bilgi tabanlarında daha etkin ve sürdürülebilir şekilde uygulanabilmesi için bileşenlerin dikkatli bir şekilde seçilmesi ve sistematik olarak optimize edilmesi gerekmektedir. Ayrıca gelecekteki çalışmalarımızda, her bir kategoriye özgü ayrı koleksiyonlar oluşturarak, kullanıcı sorgularının içeriğine göre ilgili kategoriye tespit eden ve bu doğrultuda yalnızca o kategoriye ait koleksiyonda bilgi araması gerçekleştiren bir yapı tasarlanması hedeflenmektedir.

### REFERENCES

- [1] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel *et al.*, "Retrieval-augmented generation for knowledge-intensive nlp tasks," *Advances in neural information processing systems*, vol. 33, pp. 9459–9474, 2020.
- [2] J. OpenAI Achiam, S. Adler, S. Agarwal, L. Ahmad, I. Akkaya, F. Aleman, D. Almeida, J. Altenschmidt, S. Altman, S. Anadkat *et al.*, "Gpt-4 technical report. arxiv," *arXiv preprint arXiv:2303.08774*, 2023.
- [3] H. Touvron, L. Martin, K. Stone, P. Albert, A. Almahairi, Y. Babaei, N. Bashlykov, S. Batra, P. Bhargava, S. Bhosale *et al.*, "Llama 2: Open foundation and fine-tuned chat models," *arXiv preprint*

arXiv:2307.09288, 2023.

- [4] G. Team, R. Anil, S. Borgeaud, J.-B. Alayrac, J. Yu, R. Soricut, J. Schalkwyk, A. M. Dai, A. Hauth, K. Millican *et al.*, “Gemini: a family of highly capable multimodal models,” *arXiv preprint arXiv:2312.11805*, 2023.
- [5] A. Pal, L. K. Umapathi, and M. Sankarasubbu, “Med-halt: Medical domain hallucination test for large language models,” *arXiv preprint arXiv:2307.15343*, 2023.
- [6] S. Bubeck, V. Chadrasekaran, R. Eldan, J. Gehrke, E. Horvitz, E. Kamar, P. Lee, Y. T. Lee, Y. Li, S. Lundberg *et al.*, “Sparks of artificial general intelligence: Early experiments with gpt-4,” 2023.
- [7] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel *et al.*, “Retrieval-augmented generation for knowledge-intensive nlp tasks,” *Advances in neural information processing systems*, vol. 33, pp. 9459–9474, 2020.
- [8] M. Cheng, Y. Luo, J. Ouyang, Q. Liu, H. Liu, L. Li, S. Yu, B. Zhang, J. Cao, J. Ma *et al.*, “A survey on knowledge-oriented retrieval-augmented generation,” *arXiv preprint arXiv:2503.10677*, 2025.
- [9] G. P. Wellawatte, H. Guo, M. Lederbauer, A. Borisova, M. Hart, M. Brucka, and P. Schwaller, “Chemlit-qa: a human evaluated dataset for chemistry rag tasks,” *Machine Learning: Science and Technology*, vol. 6, no. 2, p. 020601, 2025.
- [10] C. Wang, Q. Long, M. Xiao, X. Cai, C. Wu, Z. Meng, X. Wang, and Y. Zhou, “Biorag: A rag-llm framework for biological question reasoning,” *arXiv preprint arXiv:2408.01107*, 2024.
- [11] M. Raja, E. Yuvarajan *et al.*, “A rag-based medical assistant especially for infectious diseases,” in *2024 International Conference on Inventive Computation Technologies (ICICT)*. IEEE, 2024, pp. 1128–1133.
- [12] N. Wiratunga, R. Abeyratne, L. Jayawardena, K. Martin, S. Massie, I. Nkisi-Orji, R. Weerasinghe, A. Liret, and B. Fleisch, “Cbr-rag: case-based reasoning for retrieval augmented generation in llms for legal question answering,” in *International Conference on Case-Based Reasoning*. Springer, 2024, pp. 445–460.
- [13] R. Kalra, Z. Wu, A. Gulley, A. Hilliard, X. Guan, A. Koshiyama, and P. Treleaven, “Hypa-rag: A hybrid parameter adaptive retrieval-augmented generation system for ai legal and policy applications,” *arXiv preprint arXiv:2409.09046*, 2024.
- [14] A. Narimani and S. Klarmann, “Integration of large language models for real-time troubleshooting in industrial environments based on retrieval-augmented generation (rag).”
- [15] A. Deshpande, V. Murahari, T. Rajpurohit, A. Kalyan, and K. Narasimhan, “Toxicity in chatgpt: Analyzing persona-assigned language models,” *arXiv preprint arXiv:2304.05335*, 2023.
- [16] Y. Chang, X. Wang, J. Wang, Y. Wu, L. Yang, K. Zhu, H. Chen, X. Yi, C. Wang, Y. Wang *et al.*, “A survey on evaluation of large language models,” *ACM transactions on intelligent systems and technology*, vol. 15, no. 3, pp. 1–45, 2024.
- [17] V. Rawte, A. Sheth, and A. Das, “A survey of hallucination in large foundation models,” *arXiv preprint arXiv:2309.05922*, 2023.
- [18] Z. Jiang, F. F. Xu, L. Gao, Z. Sun, Q. Liu, J. Dwivedi-Yu, Y. Yang, J. Callan, and G. Neubig, “Active retrieval augmented generation,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, 2023, pp. 7969–7992.
- [19] G. Izacard, P. Lewis, M. Lomeli, L. Hosseini, F. Petroni, T. Schick, J. Dwivedi-Yu, A. Joulin, S. Riedel, and E. Grave, “Few-shot learning with retrieval augmented language models,” *arXiv preprint arXiv:2208.03299*, vol. 1, no. 2, p. 4, 2022.
- [20] S. Robertson, H. Zaragoza *et al.*, “The probabilistic relevance framework: Bm25 and beyond,” *Foundations and Trends® in Information Retrieval*, vol. 3, no. 4, pp. 333–389, 2009.
- [21] W. X. Zhao, J. Liu, R. Ren, and J.-R. Wen, “Dense text retrieval based on pretrained language models: A survey,” *ACM Transactions on Information Systems*, vol. 42, no. 4, pp. 1–60, 2024.
- [22] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel *et al.*, “Retrieval-augmented generation for knowledge-intensive nlp tasks,” *Advances in neural information processing systems*, vol. 33, pp. 9459–9474, 2020.
- [23] A. Topalli, “Ekobot: Türkçe destekli akıllı sanal akademik danışman,” *International Journal of Advances in Engineering and Pure Sciences*, vol. 37, no. 2, pp. 196–205.